基于冻结视觉特征与核回归融合的房价预测

Shifeng Chen Haoxuan Ying
1686631 1255329
墨尔本大学，COMP90086 计算机视觉

I. 引言

房屋售价预测需要综合房屋自身属性与外部环境，包括面积、房屋状况、地理位置和市场条件。外观照片提供了其中一部分信息：计算机视觉可以描述建筑形态、表面外观、庭院绿化及周边场景。然而，单张照片的覆盖范围有限，也无法直接给出建筑面积、精确地址或交易条件。基于这一背景，本研究探讨如何更有效地提取房屋图像中的视觉特征，从而更准确地预测房屋售价。

这一问题可以从不同层次的视觉表示入手。传统手工局部描述子概括梯度与纹理模式，而 AlexNet [1] 等卷积网络能够从训练图像中学习层次化特征。随着大规模预训练的发展，视觉表示可以在不同任务之间复用。CLIP [2]、SigLIP2 [3] 和 Perception Encoder [4] 提供了这类表示，使冻结编码器、单独学习任务回归器成为可行路线。

据此，本研究分三个阶段展开，各阶段检验前序实验暴露出的限制。首先，使用 SIFT 与视觉词袋检验局部外观是否包含价格信号；随后，引入 AlexNet 回归模型，通过训练调优、数据增强和架构对照逐步改进。尽管这些调整改善了基线，剩余误差仍然较大，因此第三阶段转向冻结预训练特征，进一步研究图像覆盖、特征变换与回归方式如何影响价格预测，并组合互补分支。

最终三编码器融合的验证 MSE 为 52,201.21，MAE 为 159.58；全量重拟合后的 Kaggle 公榜 MSE 为 47,291.35。后续分析将这些收益与视觉表示及核回归设计联系起来，同时考察持续存在的高价低估和不同价位之间不均匀的改善。

II. 方法

A. 数据、指标与评价方法

数据集包含来自南加州房产挂牌信息的 8,000 张有标签训练图像和 3,000 张无标签测试图像，价格单位为千美元。模型使用课程提供的图像和价格拟合，通用预训练图像编码器提供可迁移的视觉特征。

我们使用种子 2026 固定划分 6,399 张训练图像和 1,601 张验证图像，将已识别的重复或关联图像保留在同一组中。对于 N 张评价图像，记真实价格为 y_i，预测价格为 $\hat{y}_i$，则

$$\mathrm{MSE} = \frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2, \qquad \mathrm{MAE} = \frac{1}{N}\sum_{i=1}^{N}|\hat{y}_i - y_i|. \quad (1)$$

主要指标 MSE 对较大误差更敏感，MAE 衡量平均绝对误差。两者单位分别为（千美元）^{2} 和千美元；有符号残差 $\hat{y}_i - y_i$ 用于描述预测偏差。

随机训练模型先使用种子 2026 初筛，有希望的候选再以种子 2027 和 2028 复核。当三种子的平均 MSE 下降，且至少两次同种子配对比较改善时，保留相应改动，并报告三种子均值与配对结果。冻结特征回归器通过训练集上的分组三折折外预测（OOF）选择。视觉词典、标准化器、PCA 和监督变换均在各折训练部分拟合。

B. 基线与 CNN 受控实验

我们首先以训练集均价建立不使用图像的参照。为检验局部外观能否提供额外信息，提取灰度 SIFT 描述子 [5], [6]，构建包含 256 个视觉词的词典 [7]。直方图依次进行 L1 归一化、平方根变换、L2 归一化及标准化，再拟合岭回归 [8]（$\alpha = 10$）。虽然这种表示能够描述局部梯度结构，但直方图汇总会丢失空间排列，因此进一步引入直接从图像学习特征组合的 CNN。

AlexNet 风格回归网络 [1] 由五个卷积层和 9216–4096–4096–1 的预测头组成，从随机初始化开始训练。经过预处理比较，选定直接缩放至 224×224，使用均值和标准差均为 0.5 的 RGB 归一化，不进行滤波。保留配置为 AdamW [9]，学习率与权重衰减均为 10^{-4}，dropout [10], [11] 为 0.5。每个微批次包含 4 张图像，累积 8 次梯度，得到有效批量 32。训练时将价格除以 1,000，预测时恢复至数据集尺度。每次最多训练 60 轮，至少训练 40 轮，早停耐心为 15 轮，有效改善阈值为 0.1%；保存验证 MSE 严格最低的检查点。

为检验优化敏感性，代表性初筛使用学习率 3×10^{-5}、10^{-4}、3×10^{-4} 和 10^{-3}，有效批量 16/32/64，以及 dropout 0/0.2/0.5。实验比较包含 Adam [12] 的优化器、不重启的余弦衰减 [13]、有效批量、正则化和初始化 [14], [15]，再研究数据增强。几何变换与退化变换分别测试，其中水平翻转的概率为 0.5。架构实验借鉴小核堆叠 [16]，用两个 3×3 卷积替换第二个 5×5 卷积，检验局部特征组合；通过 Inception 风格的多尺度模块 [17] 比较不同感受野；通过投影残差连接 [18] 检验特征复用。为检验大型预测头在有限监督下是否过拟合，我们将 6×6 卷积特征投影到 128 维，加入位置信息与归一化，对 36 个 token 求均值后进行线性回归。随后测试单层 Transformer [19]，维度为 128，注意力头数为 4，前馈层维度为 512。每项改动均与对应对照比较。

另以种子 2026 进行独立的光度增强初筛：亮度或对比度分别在每张训练图像上使用从 $[0.9, 1.1]$ 均匀抽取的倍率，在缩放与归一化前应用。两者均与新训练的无增强 AlexNet 比较，保持初始化、划分和训练设置一致。

C. 冻结表示、多视图与回归

为进一步改进从零训练模型，我们将视觉表示与价格回归分开研究。冻结 CLIP ViT-B/32 特征经标准化后结合岭回归，建立迁移学习参照；最终分支使用 SigLIP2 So400m NaFlex、PE-Core-L/14 和 PE-Core-G/14。NaFlex 使用 576 个 patch 保留原始宽高比，输出 1,152 维特征。考虑到单次裁剪可能移除有用环境，PE-L 组合三个 1,024 维视图：官方输入、336 像素灰色补边整图，以及保留原图宽高各

60% 的中央裁剪。PE-G 组合官方 448 像素视图与灰色补边整图。各视图特征先独立单位化，拼接后再次单位化，得到 3,072 维 PE-L 特征和 2,560 维 PE-G 特征。

我们使用 RBF 核岭回归 [20] 描述冻结特征空间中的非线性关系，并通过正则化控制拟合系数。单位特征的平方距离等于一减余弦相似度的两倍，因此 γ 控制局部视觉近邻如何影响价格。对于 x：

$$K_{ij} = \exp(-\gamma \|x_i - x_j\|^2), \quad c = (K + \alpha I)^{-1}(y - \bar{y}\mathbf{1}). \quad (2)$$

预测为 $\bar{y} + k(x)^T c$，并将负预测截断为零。普通核回归在训练折中搜索 $\gamma \in \{1, 4, 16\}$ 和 $\alpha \in \{0.01, 0.1, 1, 10\}$。NaFlex 选定 $\gamma = 1$、$\alpha = 0.1$。

然而，通用视觉相似度也可能强调与价格无关的变化。因此，PE-L 通过折内拟合的偏最小二乘（PLS） [21], [22] 学习价格相关方向。每折拟合 16 个分量，选定预测头使用前四个标准化得分 s，构造乘积核：

$$k(x, x') = \exp\left(-\|x - x'\|^2 - 0.1\frac{\|s - s'\|^2}{4}\right), \quad (3)$$

其中 $\alpha = 1$。PLS 得分在保持图像编码器冻结的同时，将价格相关方向引入相似度计算。

与监督式 PLS 不同，PCA [23] 不使用价格，而是沿主要变化方向压缩特征。对于 PE-G，我们比较 64、256 和 1,024 维，白化幂取 0 和 0.5，变换后再次单位化。由于这会改变特征距离，我们同时对原有 $\gamma = 4$ 进行校准：

$$\gamma' = 4\frac{\text{median}\,\|x_i - x_j\|^2}{\text{median}\,\|z_i - z_j\|^2}. \quad (4)$$

其中 z 为变换后的单位向量，中位数由各折训练部分固定抽取的 8,192 对不同图像计算。最终选定不白化的 PCA256，$\alpha = 1$。

D. 融合与最终重拟合

借鉴堆叠回归 [24]，各分支以非负权重融合，并增加权重总和为 1 的约束。权重由训练 OOF 预测拟合，并通过元模型交叉拟合评价：每折使用其余折拟合的权重预测。当新增分支使 meta-CV MSE 至少改善 1%，至少两折改善，且验证 MSE 同时下降时，保留该分支。

最终权重分别为 NaFlex 0.108065、PE-L PLS 0.080806、PE-G PCA 0.811129。生成 Kaggle 提交时，保持选定超参数和融合权重，在全部 8,000 张有标签图像上重新拟合变换与回归头，并重新计算训练集的 PCA 和带宽统计，再预测 3,000 张测试图像的价格。

III. 结果

A. 局部证据与学习型表示的必要性

训练均价预测的 MSE 为 151,839.69，SIFT–BoVW–Ridge 将其降至 $145,336.73 \pm 1,091.58$，表明局部外观包含有限的价格信号。考虑到词袋汇总丢失空间排列，我们进一步检验能够学习特征组合的 CNN。补边 AlexNet 的平均 MSE 为 128,415.68，直接缩放后降至 127,774.42（表 I）。这促使我们继续考察训练方式和模型容量能否解释剩余误差。

TABLE I
固定验证集上的代表性结果。

方法	MSE	MAE
参照基线		
训练均价	151,840	294.47
SIFT–BoVW–Ridge	145,337	288.66
A. 表示路线		
AlexNet	127,774	264.52
AlexNet + 翻转	126,810	268.02
翻转 AlexNet + 均值头	122,334	261.48
CLIP B/32 + 岭回归	91,821	223.27
B. 冻结分支与融合		
NaFlex + RBF	63,086	181.28
PE-L（三视图）+ RBF	59,213	172.90
PE-L（三视图）+ PLS/RBF	59,483	171.73
PE-G（官方视图）+ RBF	55,097	165.80
PE-G（双视图）+ RBF	53,253	161.88
PE-G（双视图）+ PCA/RBF	52,806	160.67
三编码器融合	**52,201**	**159.58**

$n = 1{,}601$；MSE 单位为（千美元）^{2}，MAE 为千美元。SIFT 与三个 AlexNet 结果为三种子均值；冻结特征行使用选定拟合。

TABLE II
融合消融与强单分支对照。

配置	验证 MSE	Meta MSE
仅 PE-G PCA	52,805.77	52,531.27
移除 NaFlex	52,597.50	52,359.30
移除 PE-L PLS	52,194.81	52,244.24
移除 PE-G PCA	57,372.90	57,694.20
等权融合	53,847.68	54,214.33
完整融合	52,201.21	52,210.22

移除分支后，仅在训练 OOF 上重新拟合其余权重。验证集 n=1,601；meta 为训练侧三折交叉拟合 MSE。

B. 先检验训练与容量，再转向迁移表示

同种子对照未提供充分证据支持优化策略调整。学习率为 0.001 的 Adam 只在种子 2026 改善，另外两次退步，平均 MSE 增加 509.89；余弦衰减、替代批量和较低 dropout 也未通过保留条件。水平翻转则以两次配对获胜使平均 MSE 降低 964.41，但 MAE 从 264.52 升至 268.02。擦除在初筛中改善，却只在三次配对复核中获胜一次，因此放弃。保留方案依据重复证据，而非最好的初筛分数。

为检验大型预测头是否限制学习，我们使用均值池化替换它。三个种子均改善，相对翻转 AlexNet 的 MSE 降低 4,475.78。小卷积核、多尺度和残差初筛未超过对照；Transformer 相对紧凑头的单种子 MSE 增加 3,615.11。因此，增加容量未解决当前条件下的预测困难。

光度增强暴露了另一种权衡。相对新训练的种子 2026 对照（MSE 131,389.94，MAE 282.64），亮度得到 131,433.91 与 274.50，对比度得到 128,860.53 与 269.01。对比度总体 MSE 改善 1.93%，但高于 1,300 的尾部 MSE 恶化 17.14%；亮度使其恶化 3.86%。因此，平均误差下降未必改善高价房屋，且两项仍属于单种子初筛。

保留的从零模型仍有较大误差，而冻结 CLIP 与岭回归达到 MSE 91,820.73，推动后续转向更丰富的迁移视觉表示。这是同时改变表示与读出方式的完整路线比较。

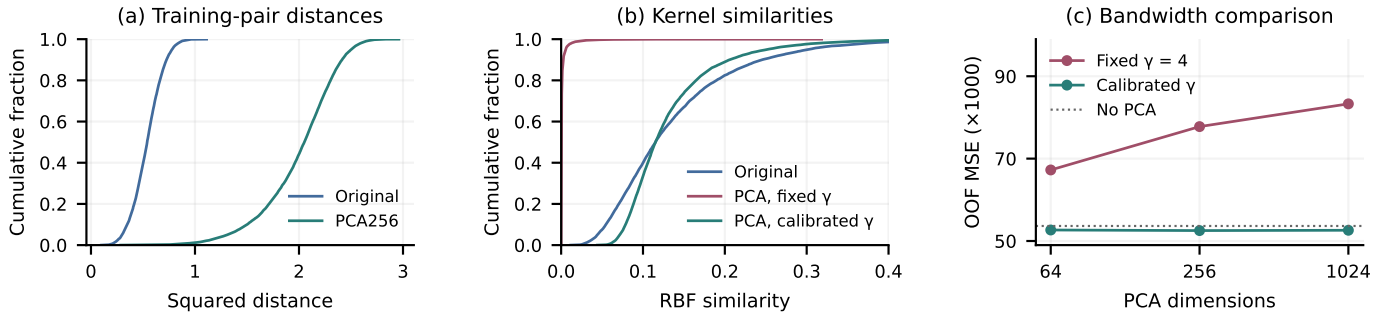


Fig. 1. PE-G 几何与回归诊断。（a、b）8,192 对训练样本的距离与核相似度经验累积分布；（c）不白化 PCA 的分组三折 OOF MSE。变换与带宽均在各折内拟合；（b）展示相似度 0–0.4 范围。

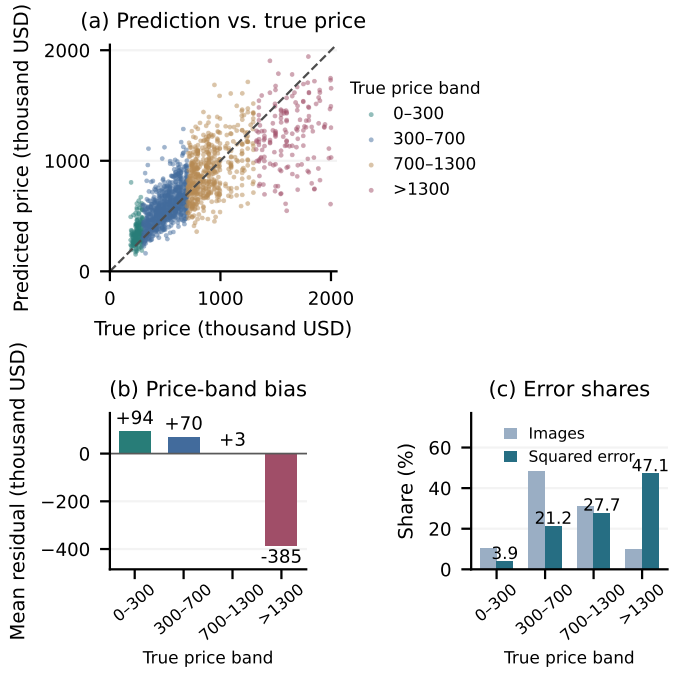


Fig. 2. 最终融合在 1,601 张验证图像上的表现。（a）预测与真实价格，虚线为理想预测，颜色对应（b）的价位区间；（b）平均残差 $\hat{y} - y$；（c）样本与平方误差占比。价位区间为 $(0, 300]$、$(300, 700]$、$(700, 1300]$ 和高于 1,300 千美元。

C. 恢复环境覆盖，再修复核几何

为 PE-G 官方视图补充整图后，验证 MSE 从 55,097.49 降至 53,252.81，OOF MSE 从 55,679.73 降至 53,646.46，支持扩大图像覆盖。

然而，使用 PCA256 压缩特征并沿用 $\gamma = 4$ 时，OOF MSE 恶化至 77,771.43。训练平方距离中位数从 0.5402 变为 2.0515，因此将 γ 校准为 1.05323（图 1）。OOF MSE 降至 52,531.27，验证 MSE 达到 52,805.77，MAE 为 160.67。距离变化解释了为何压缩必须与下游相似度尺度共同评价，但不能证明 PCA 只移除了无关信息。

监督适配也并非始终有利：PE-L PLS 相对同一三视图 RBF 对照的验证 MSE 略有恶化，但 MAE 改善。因此，应通过与其他分支的互补性评估其用途，不能仅因使用价格监督就假定有效。

D. 分支互补与剩余估价歧义

加入 PE-G PCA 后，meta-CV MSE 从 53,052.57 降至 52,210.22，三折均改善；验证 MSE 从 52,524.78 降至 52,201.21；公榜 MSE 从 47,837.69 变为 47,291.35。

表 II检验融合是否超越最强单分支。融合相对 PE-G PCA 改善 1.14%；移除 PE-G 的代价最大，等权则削弱其贡献。去掉 PE-L 后验证 MSE 略降，但 meta-CV 恶化，其收益较小且依赖评价标准。这些是整条分支移除对照，无法单独验证 PCA 或 PLS。

总体改善仍留下新问题：平均残差 +6.51 掩盖了低价高估（不超过 300 时为 +93.72）和高价低估（超过 1,300 时为 −385.16）。159 张最高价图像贡献平方误差的 47.13%（图 2），误差最大的 161 张贡献 63.30%。RMSE 为 228.48，绝对误差中位数为 113.41。

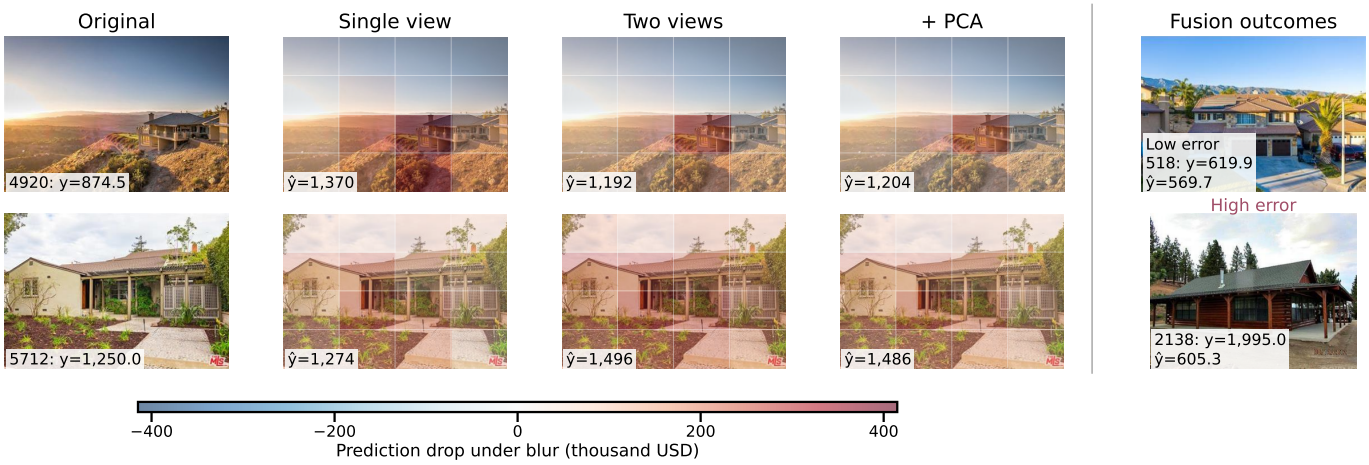


Fig. 3. 左侧四列：PE-G 单视图、双视图和 PCA 回归的 4×4 模糊替换敏感性；红色表示替换使预测下降，蓝色表示上升，全部热图共用色标。4920 和 5712 分别是 1,543 张横向验证图像中补充整图后改善与退步最大的案例。右列为不同的最终融合样本：518 位于绝对误差第 25 百分位，2138 为固定失败案例。价格单位为千美元。

E. 案例与区域敏感性

图 3右列对照成功与失败案例。图像 518 位于绝对误差第 25 百分位，绝对误差为 50.17；木质外观房屋 2138 则被严重低估。两者均完整展示建筑，说明覆盖充分的图像仍可能产生较大估价误差。其视觉差异提出了值得进一步研究的问题，但不能据此认定预测准确的原因。

区域扰动 [25] 检验更局部的问题：用灰色像素或半径 8 的模糊内容替换 4×4 区域时，最大响应靠近房屋区域（图 3）。但图像 5712 的双视图模型在灰色与模糊实验间的相关系数仅为 0.267。因此，这些图表示扰动敏感性，无法可靠识别价格相关属性。

IV. 讨论

三条路线分别回答了视觉信息应如何服务于房屋估价。手工 SIFT 特征使表示方式明确可控，为局部外观建立了有用参照。然而，视觉词袋汇总丢失空间关系，使其难以区分那些价值与建筑及周边环境的排列有关的房屋。这条路线揭示了图像证据的组织方式对估价的重要性。

从零训练 CNN 则让这种组织方式能够从数据中学习。受控实验展示了优化、增强和架构如何与有限的标注数据共同影响学习过程。紧凑预测头的表现提示，使模型容量与可用监督相匹配，可能比增加架构复杂度更有效。这些发现也提醒我们，更强的表达能力并不自动保证网络学到更适合房价预测的表示。

冻结预训练编码器引入了在房价标注数据之外学到的知识，使任务学习能够集中于回归。然而，这些知识仍需适配：视图构造决定哪些证据能够经过预处理保留下来，特征变换与核几何则决定视觉相似性如何转化为价格估计。特征缓存使这种分工能够在有限硬件上实现，但稠密核仍限制可扩展性。融合能够利用不同表示的互补性，各分支的作用则不必相同。

综合三条路线，更准确的视觉房价预测需要同时考虑表示的信息量、图像覆盖以及与估价任务相适应的映射。房屋外观提供的是价值的一部分线索；图像未揭示的位置、面积和交易条件仍可能带来估价歧义。下一步应先按建筑覆盖、遮挡和场景环境比较误差，再检验针对性视图。提高高价样本抽样比例时，应检查误差是否转移至普通价位；对比度增强则需要多种子复核。由于重复使用开发数据并事先筛选分支，还需进行独立分组评价；元模型交叉拟合本身无法消除这种选择偏差。

参考文献

[1] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet classification with deep convolutional neural networks,” *Advances in Neural Information Processing Systems, vol. 25*, 2012.

[2] A. Radford et al., “Learning transferable visual models from natural language supervision,” *Proc. ICML*, 2021, pp. 8748–8763.

[3] M. Tschannen et al., “SigLIP 2: Multilingual vision-language encoders with improved semantic understanding, localization, and dense features,” *arXiv:2502.14786*, 2025.

[4] D. Bolya et al., “Perception Encoder: The best visual embeddings are not at the output of the network,” *arXiv:2504.13181*, 2025.

[5] D. G. Lowe, “Object recognition from local scale-invariant features,” *Proc. ICCV*, 1999, pp. 1150–1157.

[6] D. G. Lowe, “Distinctive image features from scale-invariant keypoints,” *International Journal of Computer Vision, vol. 60*, 2004, pp. 91–110.

[7] J. Sivic and A. Zisserman, “Video Google: A text retrieval approach to object matching in videos,” *Proc. ICCV*, 2003, pp. 1470–1477.

[8] A. E. Hoerl and R. W. Kennard, “Ridge regression: Biased estimation for nonorthogonal problems,” *Technometrics, vol. 12*, 1970, pp. 55–67.

[9] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” *Proc. ICLR*, 2019.

[10] G. E. Hinton et al., “Improving neural networks by preventing co-adaptation of feature detectors,” *arXiv:1207.0580*, 2012.

[11] N. Srivastava et al., “Dropout: A simple way to prevent neural networks from overfitting,” *Journal of Machine Learning Research, vol. 15*, 2014, pp. 1929–1958.

[12] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” *Proc. ICLR*, 2015.

[13] I. Loshchilov and F. Hutter, “SGDR: Stochastic gradient descent with warm restarts,” *Proc. ICLR*, 2017.

[14] X. Glorot and Y. Bengio, “Understanding the difficulty of training deep feedforward neural networks,” *Proc. AISTATS*, 2010, pp. 249–256.

[15] K. He et al., “Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification,” *Proc. ICCV*, 2015, pp. 1026–1034.

[16] K. Simonyan and A. Zisserman, “Very deep convolutional networks for large-scale image recognition,” *Proc. ICLR*, 2015.

[17] C. Szegedy et al., “Going deeper with convolutions,” *Proc. CVPR*, 2015, pp. 1–9.

[18] K. He et al., “Deep residual learning for image recognition,” *Proc. CVPR*, 2016, pp. 770–778.

[19] A. Vaswani et al., “Attention is all you need,” *Advances in Neural Information Processing Systems, vol. 30*, 2017.
[20] C. Saunders, A. Gammerman, and V. Vovk, “Ridge regression learning algorithm in dual variables,” *Proc. ICML*, 1998, pp. 515–521.
[21] H. Wold, “Estimation of principal components and related models by iterative least squares,” *Multivariate Analysis, P. R. Krishnaiah, Ed. Academic Press*, 1966, pp. 391–420.
[22] S. Wold, A. Ruhe, H. Wold, and W. J. Dunn III, “The collinearity problem in linear regression. The partial least squares (PLS) approach to generalized inverses,” *SIAM Journal on Scientific and Statistical Computing, vol. 5*, 1984, pp. 735–743.
[23] K. Pearson, “On lines and planes of closest fit to systems of points in space,” *Philosophical Magazine, vol. 2*, 1901, pp. 559–572.
[24] L. Breiman, “Stacked regressions,” *Machine Learning, vol. 24*, 1996, pp. 49–64.
[25] M. D. Zeiler and R. Fergus, “Visualizing and understanding convolutional networks,” *Proc. ECCV*, 2014, pp. 818–833.