利用房屋照片预测价格：从 AlexNet 改进到预训练特征组合

Shifeng Chen 1686631　　Haoxuan Ying 1255329
COMP90086 Computer Vision, The University of Melbourne

I. Introduction：任务与解决思路

本项目使用课程提供的南加州房屋照片预测价格 [1], [2]。照片能显示建筑外观、庭院和周边环境，但不一定包含位置、面积和内部装修等重要信息。因此，我们关注的不只是最终分数，也包括：模型能从照片中学到什么，哪些改动有帮助，以及哪些问题仍未解决。

我们先用训练集均价和 SIFT 特征建立比较起点，再训练 AlexNet。针对图片尺寸不一和过拟合，比较预处理、训练设置、增强与结构调整。多数改动收益小，简化回归头则在三个种子上都有效。之后转向固定预训练编码器，重点检查“图片内容是否被保留”和“特征相似度是否适合预测价格”。在整图视野、PCA 与核带宽对照后，组合三条预测路线，得到验证 MSE 52,201.21、MAE 159.58，历史公开榜 MSE 47,291.35。本文按发现问题、尝试改进和检查结果的过程展开，而不把所有改动都解释为成功。

II. Methods：数据与实验设置

A. 数据划分及指标

仅使用课程的 8,000 张有标签图像与 3,000 张测试图像，价格单位为千美元。为减少重复照片影响比较，我们把已发现的完全重复及近重复图片放入同一组，再按组价格分层，固定划分为 6,399 张训练图和 1,601 张验证图。两侧没有相同图片编号、已登记的重复组或像素哈希，但仍可能存在未发现的同一房屋照片。所有方法使用这份划分；种子 2026、2027、2028 只改变训练随机性。测试标签不用于调参，也未添加原始 SoCal 数据集中的其他图片或房屋信息。

主指标与辅助指标分别为

$$\mathrm{MSE}=\frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i-y_i)^2,\qquad \mathrm{MAE}=\frac{1}{n}\sum_{i=1}^{n}|\hat{y}_i-y_i|. \quad (1)$$

MSE 对大误差惩罚更重，MAE 表示平均绝对误差，单位分别为 (千美元)^2 和千美元。另检查价格大于 1,300 的高价房（训练价格的 90% 分位数；验证集 159 张）。随机模型先用种子 2026 初筛，有希望的方案再用 2027、2028 复核；三种子均值下降且至少两次配对改善才保留。报告均值和样本标准差，不把它们当作模型集成成绩。

B. 建立比较起点

最简单的方法对所有图片预测训练集均价，用于检查图像是否提供额外信息。传统方法提取灰度 SIFT [3]，构建 256 词视觉词袋，对词频直方图进行 L1、平方根、L2 归一化及标准化，接岭回归（$\alpha=10$）。词典、标准化参数和回归器只在训练部分学习。

AlexNet [4] 从随机权重训练，由五个卷积层和 9216–4096–4096–1 回归头组成。价格先除以 1,000 计算损失，报告时恢复原单位。保留配置为 224×224 拉伸、通道归一化均值和标准差均为 0.5、AdamW 学习率与 weight decay 均为 10^{-4}、有效批量 32（4×8 梯度累积）、dropout 0.5。至少训练 40 轮、最多 60 轮，早停耐心 15 轮、改善阈值 0.1%，恢复验证 MSE 最低的检查点。增强只用于训练，验证关闭增强和 Dropout。小头实验将 6×6 特征投影至 128 维，加入位置与归一化后对 36 个 token 求均值；单层 Transformer 使用 4 个注意力头、512 维前馈层。

C. 预训练特征与模型组合

先以冻结 CLIP ViT-B/32 [5] 加标准化岭回归作为迁移学习参照。最终三条路线使用 SigLIP 2 So400m NaFlex [6]、PE-Core-L/14 和 PE-Core-G/14 [7] 的图像特征，不更新编码器，也不使用 MLLM 或现成房价模型。NaFlex 保留宽高比，使用 576 个 patch，输出 1,152 维；PE-L 组合官方输入、336 像素灰色补边整图和保留宽高各 60% 的中心裁剪；PE-G 组合官方 448 像素视图与补边整图。各视图先单位化，拼接后再单位化，得到 3,072 维 PE-L 和 2,560 维 PE-G 特征。预测部分使用 RBF 核岭回归（KRR）[8]：

$$K(x,x')=\exp(-\gamma\|x-x'\|^2),\qquad \boldsymbol{a}=(K+\alpha I)^{-1}(\boldsymbol{y}-\bar{y}). \quad (2)$$

直观上，核衡量图片特征的相似度，γ 控制相似度下降的速度，α 控制正则化。预测加回训练均价并将负值截为零。普通核搜索 $\gamma\in\{1,4,16\}$、$\alpha\in\{0.01,0.1,1,10\}$，NaFlex 选择 $\gamma=1,\alpha=0.1$。

通用视觉相似并不一定代表价格接近。PE-L 因此用 PLS [9] 学习价格相关方向：折内拟合 16 个分量，最终使用前 4 个标准化得分 s，核为 $\exp(-\|x-x'\|^2-0.1\|s-s'\|^2/4)$，$\alpha=1$。PE-G 则用不需要价格的 PCA [10] 压缩特征，比较 64、256、1,024 维及白化幂 0、0.5，再单位化。压缩改变距离，因此另比较以下带宽调整：

$$\gamma'=4\frac{\mathrm{median}\,\|x_i-x_j\|^2}{\mathrm{median}\,\|z_i-z_j\|^2}, \quad (3)$$

其中 z 为变换后特征，中位数用拟合折内固定抽取的 8,192 对不同图片计算。最终保留不白化的 PCA256，$\alpha=1$。PCA、PLS 及缩放参数均只在对应训练折学习。

将训练集按组分为三折，每次用两折训练、预测剩下一折，得到每张图片未参与该次训练时的 OOF 预测。再借鉴堆叠回归 [11]，用这些预测学习非负且和为 1 的权重：

$$\hat{y}=\sum_{j=1}^{3}w_j\hat{y}_j,\quad \boldsymbol{w}=(0.1081,\,0.0808,\,0.8111). \quad (4)$$

TABLE I

METHOD OVERVIEW ON THE SAME 1,601 VALIDATION IMAGES. ±: SAMPLE SD ACROSS THREE SEEDS; OTHER ROWS: ONE SELECTED CONFIGURATION.

Method	MSE	MAE
Training mean	151,839.69	294.47
SIFT–BoVW–Ridge	$145,336.73 \pm 1,091.58$	288.66
AlexNet (no aug.)	$127,774.42 \pm 486.30$	264.52
AlexNet (H-flip)	$126,810.01 \pm 1,902.23$	268.02
Mean-pool head	$122,334.22 \pm 1,588.64$	261.48
CLIP B32 + Ridge	91,820.73	223.27
NaFlex KRR	63,086.48	181.28
PE-L PLS KRR	59,483.31	171.73
PCA PE-G KRR	52,805.77	160.67
Final fusion	**52,201.21**	**159.58**

TABLE II

HISTORICAL AUGMENTATION SCREEN (SEED 2026). ΔMSE IS RELATIVE TO THE SAME-BATCH CONTROL; NEGATIVE IS BETTER.

Operation / parameters	MSE	ΔMSE
No augmentation	128,268.67	0
H-flip: $p = 0.5$	126,601.97	$-1,666.70$
Rotation: $p = 0.3$, $\pm 3°$	129,526.18	$+1,257.51$
Translation: $p = 0.3$, ±3%/axis	129,162.73	$+894.06$
Crop: $p = 0.3$, area 90–100%	130,222.98	$+1,954.31$
Blur: $p = 0.2$, $\sigma = 0.3$–0.8	129,941.36	$+1,672.69$
Noise: $p = 0.2$, $\sigma = 0.01$	131,174.53	$+2,905.87$
Erasing: $p = 0.15$, area 1–3%	128,114.40	-154.27

TABLE III

PHOTOMETRIC SCREEN WITH A FRESH, SAME-BATCH CONTROL (ONE SEED). TAIL: 159 IMAGES WITH PRICE $> 1,300$ THOUSAND USD.

Setting	MSE	MAE	Tail MSE
Control	131,389.94	282.64	593,970.49
Brightness	131,433.91	274.50	616,903.93
Contrast	128,860.53	269.01	695,747.66

验证标签不用于拟合权重。用两折 OOF 预测学权重、在剩下一折评价，记为 meta-crossfit；基础模型已被筛选，它不是完全独立测试。新增分支需让 meta MSE 降低至少 1%、至少两折改善且验证 MSE 下降。最终固定超参数和权重，在 8,000 张有标签图上重拟合变换、核带宽与回归器，生成 3,000 条测试预测。

III. RESULTS：问题、尝试与改进

A. 先检查图像信息与输入处理

表I汇总相同验证集上的结果。SIFT 相比均价只降低 4.28% 的 MSE，说明局部图像信息有用，但作用有限。一个可能原因是词袋统计保留了局部纹理，却弱化了它们在图中的位置，难以区分整栋房屋的布局。AlexNet 的结果更好，因此我们继续以它为基础检查输入处理和训练方法，而不是只增加传统特征数量。

图片大小和比例不一，首先需要统一输入。我们比较等比补边、拉伸、中心裁剪、320 分辨率、通道标准化，以及空间/频域低通。频域滤波在种子 2026 初筛最好（127,610.87），但三种子仅 1 次胜过对应对照；直接拉伸则 2/3 改善，均值 127,774.42 略低于滤波的 127,886.38 和补边的 128,415.68，因此保留拉伸。拉伸可能让房屋占用更多有效像素，但也改变比例；滤波可能减弱无关纹理，也可能丢失有用细节。这些相反作用是收益仅约 0.50% 的可能解释，尚不能单独证实。滤波加拉伸也没有超过单项，说明改动不能简单叠加。

我们也检查了学习率、优化器、调度、批量和 Dropout。初筛有改善的 Adam 未在三种子平均结果上胜出，余弦调度也未优于固定学习率。这提示问题可能不只是“没有把训练损失降下来”，因此不再仅围绕优化器寻找提升，而继续检查过拟合和图像信息利用。

B. 用增强减少对拍摄条件的依赖

增强的思路是：同一房屋换一个位置、方向或光照，价格不应改变。如果模型过于依赖这些拍摄条件，训练时加入变化可能有帮助。表II每次只增加一种操作，与无增强 AlexNet 比较。水平翻转三种子 MSE 降低 0.75% 至 126,810.01，2/3 种子改善，故保留；但 MAE 由 264.52 升至 268.02，说明并非所有误差都变小。擦除初筛略好，复核均值却为 128,300.21、仅 1/3 改善，因此放弃。

翻转保留了大部分可见内容，可能比裁剪、擦除更少损失信息。相反，裁剪可能去掉庭院或建筑边缘，模糊和噪声可能遮盖细节；而这些细节本身也可能与价格有关。这可以解释为何增强没有普遍有效，但我们没有逐项验证原因，其他操作也只做了单种子初筛。依据现有结果，我们没有继续叠加未证实有效的增强。

后期补做亮度和对比度实验，使用相同初始化、固定划分和种子 2026，分别以概率 1 采样乘数 $U(0.9, 1.1)$，不叠加其他增强，各训练 40 轮。表III中亮度 MSE 基本不变；一种可能是原图已有照明差异，小幅亮度变化没有补充多少新变化。对比度 MSE 下降 1.93%，可能减轻了对特定明暗纹理的依赖，但高价房 MSE 反而增加 17.14%。我们无法确定这是细节被削弱还是训练波动，因此只将其列为待复核方案，没有加进最终模型。这组结果只与同期控制组 131,389.94 比较，不与旧批次混比。

C. 训练表现停滞时，是否应增加复杂度？

光度对照的最佳验证点在第 7、11 和 5 轮，此后训练误差下降却未持续改善验证表现，与过拟合相符。因此使用最佳检查点而非最后一轮；训练开启 Dropout 及对应增强，不能把训练、验证曲线间距直接视为同条件误差差距。为改善特征提取，我们在翻转 AlexNet 上分别尝试小卷积核堆叠、多尺度块和残差块。同种子对照为 126,601.97，三种改动分别为 127,319.95、130,027.49 和 128,714.26，均未保留。这些只是 AlexNet 上的局部改动，不是完整 VGG、Inception 和 ResNet 比较。可能的原因是增加结构没有解决训练样本和价格线索有限的问题，还增加了学习难度；初筛结果不足以证明这些结构普遍无效。

随后改用平均池化小回归头，三种子 MSE 降至 122,334.22，三次均优于翻转 AlexNet。较小的头减少需要拟合的参数，平均池化也降低了对具体空间位置的依赖，这可能使其更不容易记住训练图片，但两种作用尚未拆开验证。再加单层 Transformer 后，种子 2026 的 MSE 从小头的 120,774.16 变为 124,389.28。因此我们保留简单的小头，没有继续加深。结果提示：对当前数据，更复杂不一定更合适。

接下来固定预训练特征，只学习房价预测部分。CLIP 加岭回归的 MSE 降至 91,820.73，较小头改善约 24.94%，这

TABLE IV
FUSION ABLATION. VALIDATION: $n = 1,601$; META: THREE-FOLD CROSS-FITTING ON 6,399 TRAINING-SIDE OOF PREDICTIONS, NOT AN INDEPENDENT TEST.

Configuration	Val. MSE	Meta MSE
NaFlex only	63,086.48	64,475.13
PE-L PLS only	59,483.31	59,515.43
PCA PE-G only	52,805.77	52,531.27
No NaFlex; refit weights	52,597.50	52,359.30
No PE-L PLS; refit weights	52,194.81	52,244.24
No PCA PE-G; refit weights	57,372.90	57,694.20
Equal-weight fusion	53,847.68	54,214.33
Frozen full fusion	52,201.21	52,210.22

使我们进一步探索 SigLIP2 和 PE。可能是预训练特征已包含较丰富的形状、纹理和场景信息，不必仅靠 6,399 张图从头学习。但编码器和回归器同时改变，这不是单独证明预训练效果的消融。

D. 补充视野后，为什么 *PCA* 一度变差？

预训练模型也可能在输入裁剪时丢失内容。为此保留 PE-G 官方视图，再补充整图，而不是用整图完全替换。验证 MSE 由 55,097.49 降至 53,252.81，OOF MSE 由 55,679.73 降至 53,646.46，支持补充视野有用。可能是边缘房屋或周边环境得到保留，但这不能证明所有背景都有帮助。

随后尝试压缩特征，PCA256 沿用 $\gamma = 4$ 时，OOF MSE 反而升至 77,771.43。我们没有直接判定 PCA 无效，而检查它是否同时改变了核计算。图1显示，变换并单位化后，训练图片对的平方距离中位数从 0.5402 升至 2.0515；相同 γ 下，RBF 相似度因此明显减小。按式 (3) 调整带宽后，开发训练拟合的 γ' 为 1.05323，OOF MSE 降至 52,531.27，验证 MSE 为 52,805.77。这说明“换特征但保持原参数”不一定是公平比较，需要检查下游算法是否仍适用。距离图支持尺度变化这一解释，但未证明 PCA 只移除了无关信息。

加入该分支后，原组合 meta MSE 从 53,052.57 降至 52,210.22，三折均改善；验证 MSE 从 52,524.78 降至 52,201.21，达到保留条件。历史公榜相应由 47,837.69 降至 47,291.35，但该分数不替代训练侧和验证集比较。

E. 组合是否真的比单个模型好？

不同特征可能在不同图片上出错，因此我们进一步尝试加权平均预测，而不是只选一个模型。表IV逐次移除一条路线，只在训练 OOF 上重学剩余权重。PCA PE-G 单独为 52,805.77，完整组合为 52,201.21，仅再改善约 1.14%。移除 PE-G 后升至 57,372.90，而移除 NaFlex 升至 52,597.50，说明主要提升来自强单模型，其他模型只提供小幅补充。可能是它们的错误部分重合，组合无法纠正大家都预测不准的图片；尚需逐图误差相关分析验证。等权组合反而较差（53,847.68），也说明不应让较弱模型占同等比重。

PE-L PLS 是否值得保留还不明确：去掉它后验证 MSE 低 6.40（约 0.012%），但 meta MSE 高 34.02，方向不一致，不能据此认定删除更好。后续尝试校正预测的整体偏移与尺度，以及用无约束岭回归组合预测，meta MSE 分别为 52,251.89 和 52,256.36，也未超过原方案 52,210.22。因此保持最终方案不变。这里移除的是整条预测路线，不能当作单独验证 PCA 或 PLS 的实验，也未对小幅差异做显著性检验。

F. 平均分数之外：哪些图片仍然困难？

最终 RMSE 为 228.48、绝对误差中位数 113.41，平均偏差只有 $+6.51$，但图2显示低价高估和高价低估相互抵消。最低价组 MAE 为 104.03，高价组为 410.90、平均低估 385.16。高价组仅占 9.93% 样本，却贡献 47.13% 平方误差；误差最大的 161 张贡献 63.30%。最后一步组合改善也不均匀：最低、最高价位对总 MSE 变化分别贡献 -224.23、-882.25，中间两组则为 $+185.43$、$+597.48$。总变化 -323.57 并不代表每组都改善。

图3进一步检查补充视野何时有用。我们在 1,543 张横向验证图中选择改善最大 4920 与退步最大 5712，而非随机选例。4920 真实 874.5，单视图预测约 1,370，双视图降至 1,192，更接近真实值；5712 真实 1,250，却由 1,274 升至 1,496。补充场景有时纠正估计，有时反而带来误导，因此不能把“看得更多”直接等同“预测更准”。

参考区域遮挡方法 [12]，将图片分成 4×4 格，分别用灰色或半径 8 的高斯模糊内容替换一格，记录预测变化。图中较强响应与房屋区域重叠，但 5712 双视图模型的灰色/模糊响应相关系数仅 0.267，说明解释依赖替换方式。这些图只反映三种 PE-G 回归流程对扰动的敏感性，不是分割、因果证据或最终三模型组合的解释图。

IV. DISCUSSION：经验、局限与下一步

这次实验使我们逐步认识到，提升不只来自增加模型复杂度。SIFT 保留局部纹理，却弱化布局；从零训练 CNN 能学习布局，但需要同时学习特征和价格关系，较小的回归头反而更稳定。冻结编码器提供了已有视觉知识，使我们能集中改进视野和回归方式。不过，PCA 失败再恢复的例子说明，即使特征更紧凑，下游相似度计算也必须配套调整，不能只看操作本身是否常用。

高价低估可能与高价样本较少、外观信息不充分有关，但当前实验不能分离这些原因。单张照片无法直接告诉我们位置、面积或交易条件；遮挡图也不能证明模型真正理解了某个定价因素。后续应先检查高误差图片中的遮挡、主体大小与场景差异，再设计内容覆盖的对照。可尝试提高高价样本抽样比例，但必须同时检查普通价位，避免转移误差；对比度应先多种子复核并测试更小幅度。这些是尚未验证的计划，不需要增加课程以外的房屋数据。

反复使用同一验证集会带来选择偏差，meta-crossfit 也未消除先前筛选模型的影响；小幅差异应在预先固定的额外分组评价中复核。通用预训练数据来源不能完全核验，我们未添加额外 SoCal 数据，但不保证预训练零重叠。缓存特征减少重复计算，不代表大型编码器和稠密核没有成本。公开榜、固定验证及 meta 分数来自不同数据与流程，不能相互替代。最终保留三模型组合，主要依赖 PE-G，承认其他分支收益有限及高价误差仍大；更重要的收获是用对照结果决定下一步，而不是将所有尝试都累加进最终模型。

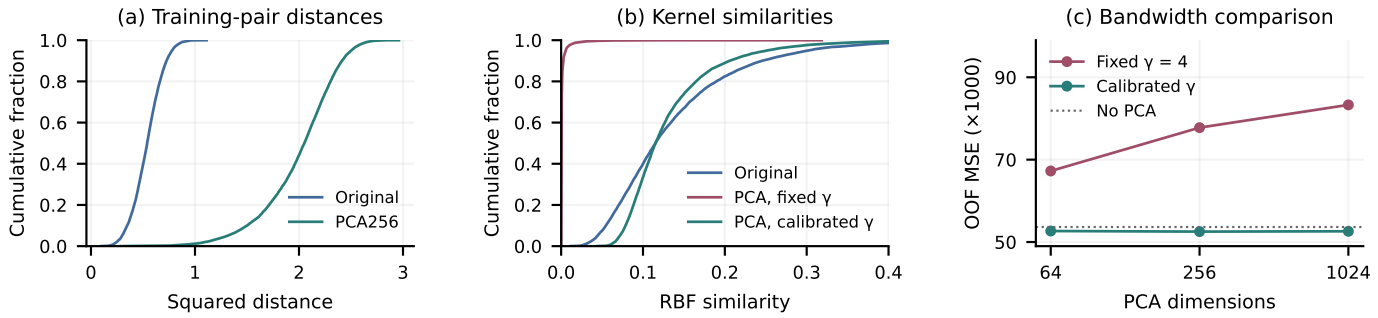


图 1. PE-G 的 PCA 诊断。(a) 8,192 对训练图片的平方距离分布；(b) RBF 相似度分布（显示 0–0.4）；(c) 不白化 PCA 在固定与校准带宽下的三折 OOF MSE。所有变换和带宽只用拟合折计算。

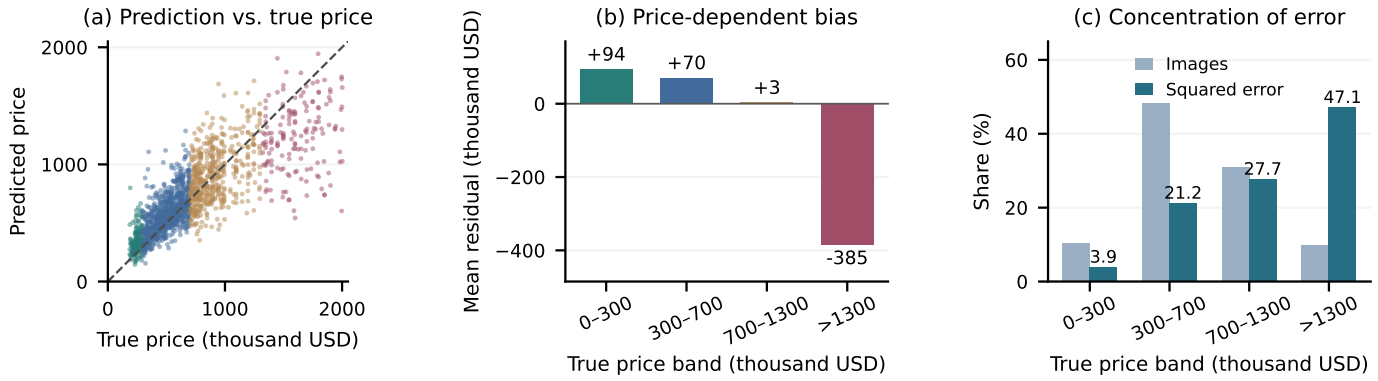


图 2. 最终组合在 1,601 张验证图上的误差。(a) 预测与真实价格；(b) 各价位平均误差（预测减真实）；(c) 样本与平方误差占比。四组为 $(0, 300]$、$(300, 700]$、$(700, 1300]$、> 1300 千美元，数量依次 169、775、498、159。



图 3. PE-G 区域模糊替换对照：单视图、双视图、双视图加 PCA。红色表示替换后预测下降，蓝色表示上升；统一色标单位为千美元。两例分别是加入整图后改善最大和退步最大的横向验证图片，不代表总体表现。

参考文献

[1] T. Dogan, “House Prices and Images – SoCal,” 2019. [Online]. Available: https://www.kaggle.com/datasets/ted8080/house-prices-and-images-socal. 数据来源引用；实验仅使用课程提供子集。

[2] The University of Melbourne, “COMP90086 Computer Vision: Predicting House Prices,” Semester 2, 2026, project specification.

[3] D. G. Lowe, “Distinctive Image Features from Scale-Invariant Keypoints,” *International Journal of Computer Vision*, vol.60, no.2, pp.91–110, 2004.

[4] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks,” in *Advances in Neural Information Processing Systems*, vol.25, 2012.

[5] A. Radford et al., “Learning Transferable Visual Models From Natural Language Supervision,” in *Proc. ICML*, 2021, pp.8748–8763.

[6] M. Tschannen et al., “SigLIP 2: Multilingual Vision-Language Encoders with Improved Semantic Understanding, Localization, and Dense Features,” arXiv:2502.14786, 2025.

[7] D. Bolya et al., “Perception Encoder: The best visual embeddings are not at the output of the network,” arXiv:2504.13181, 2025.

[8] C. Saunders, A. Gammerman, and V. Vovk, “Ridge regression learning algorithm in dual variables,” in *Proc. ICML*, 1998, pp.515–521.

[9] S. Wold, A. Ruhe, H. Wold, and W. J. Dunn III, “The collinearity problem in linear regression. The partial least squares (PLS) approach to generalized inverses,” *SIAM J. Sci. Stat. Comput.*, vol.5, pp.735–743, 1984.

[10] K. Pearson, “On lines and planes of closest fit to systems of points in space,” *Philosophical Magazine*, vol.2, pp.559–572, 1901.

[11] L. Breiman, “Stacked regressions,” *Machine Learning*, vol.24, pp.49–64, 1996.

[12] M. D. Zeiler and R. Fergus, “Visualizing and Understanding Convolutional Networks,” in *Proc. ECCV*, 2014, pp.818–833.